

Generalized Iterative Closest Point

Mündliche Prüfung in der Vorlesung Autonome Roboter

bei Prof. Dr.-Ing. Michael Blaich

17.07.2024

Johannes Brandenburger, Moritz Kaltenstadler, Fabian Klimpel

Agenda

1. Einführung
2. Theorie
 1. Mathematische Grundlagen
 2. Standard-ICP
 3. Point-to-Plane-ICP
 4. Generalized-ICP
 5. Ergebnisse von Segal et al.
3. Demo: Eigene Implementierung in Python
4. Implementierung in ROS - Versuch
 1. Versuchsaufbau
 2. Parameterisierung
 3. Implementierung ICP & GICP
 4. Problem
 5. Zeitmessung
 6. Maps
5. Auswertung
6. Fazit
7. (Bild-)Quellen

Einführung

- ICP: **Iterative Closest Point**
 - Scan-Matching-Algorithmus
 - Schätzung der Transformation zwischen zwei Punktwolken
 - Anwendung in der Lokalisierung mit z.B. LiDAR-Sensoren
- GICP: **Generalized-ICP**
 - veröffentlicht von Segal, Haehnel & Thrun (2009)
 - Stanford University
 - Ziel: ICP-Algorithmus verbessern und verallgemeinern
 - Standard-ICP & point-to-plane in **generelles Framework** überführen
 - **probabilistische** Betrachtung
 - Nutzung **Oberflächenstruktur** aus beiden Scans (Kovarianzmatrizen) → **plane-to-plane**



Theorie - Mathematische Grundlagen

Kovarianzmatrix

- beschreibt die Streuung von Zufallsvariablen
- für Punkte in Punktwolken: Verteilung der Punkte in der Umgebung

Maximum Likelihood Estimation (MLE)

- Schätzverfahren für Parameter von Wahrscheinlichkeitsverteilungen
- der Parameter wird ausgewählt, der die beobachteten Daten am wahrscheinlichsten macht
- oft verwendet um: $\arg \max_p \dots / \arg \min_p \dots$ zu finden

Theorie - Standard-ICP

- **Iterative Closest Point** (ICP) ist ein Algorithmus, um die Transformation zwischen zwei Punktwolken zu schätzen
- vergleicht korrespondierende Punkte in beiden Wolken
- minimiert die quadratischen Abstände korrespondierender Punkte

```
1  $T \leftarrow T_0$ 
2 while not converged do
3   for  $i \leftarrow 1$  to  $N$  do
4      $m_i \leftarrow \text{FindClosestPointInA}(T \cdot b_i)$ 
5     if  $\|m_i - b_i\| \leq d_{\max}$  then
6        $w_i \leftarrow 1$ 
7     else
8        $w_i \leftarrow 0$ 
9     end
10  end
11   $T \leftarrow \arg \min_T \left\{ \sum_i w_i (\|T \cdot b_i - m_i\|)^2 \right\}$ 
12 end
```



Abbildung 1: Standard-ICP (Igor Bogoslavskyi, 2021)

Theorie - Point-to-Plane-ICP

- **Point to Plane ICP** ist eine Erweiterung des ICP Algorithmus
- vergleicht korrespondierende Punkte in einer Wolke zu Ebenen in der anderen
- Ebenen wird durch Punkt und Normalenvektor definiert

$$T \leftarrow \arg \min_T \left\{ \sum_i ((T \cdot b_i - m_i) \cdot \mathbf{n}_i)^2 \right\}$$



Abbildung 2: Point-to-Plane-ICP (Kok-Lim Low, 2004)

Theorie - Standard-ICP, Point-to-Plane, Generalized-ICP

- **Point-to-Point**
 - Standard-ICP
 - vergleicht Punkt mit Punkt
- **Point-to-Plane**
 - vergleicht Punkt mit Ebene durch Normalenvektor
- **Generalized-ICP**
 - quasi „Plane-to-Plane“
 - vergleicht die Kovarianzmatrizen der nächsten Punkte → probabilistisch
 - wenn in Ebene → Kovarianzmatrix ist „flach“




Abbildung 3: Kovarianzmatrizen (eigene Darstellung)

Theorie - GICP-Algorithmus

```
1  $T \leftarrow T_0$ 
2 while not converged do
3   for  $i \leftarrow 1$  to  $N$  do
4      $m_i \leftarrow \text{FindClosestPointInA}(T \cdot b_i)$ 
5      $d_i^{(T)} \leftarrow b_i - T \cdot m_i$            // Residuum / Abstand
6     if  $\| d_i^{(T)} \| \leq d_{\max}$  then
7        $C_i^A \leftarrow \text{computeCovarianceMatrix}(T \cdot b_i)$ 
8        $C_i^B \leftarrow \text{computeCovarianceMatrix}(m_i)$ 
9     else
10       $C_i^A \leftarrow 0$ ;  $C_i^B \leftarrow 0$ 
11    end
12  end
13   $T \leftarrow \arg \min_T \left\{ \sum_i d_i^{(T)^T} (C_i^B + T C_i^A T^T)^{-1} d_i^{(T)} \right\}$  // Maximum Likelihood Estimation
14 end
```


Theorie - GICP-Algorithmus

Variationen für Kovarianzmatrizen

$C_i^A \leftarrow \text{computeCovarianceMatrix}(T \cdot b_i)$
 $C_i^B \leftarrow \text{computeCovarianceMatrix}(m_i)$

- für **Standard-ICP** (Point-to-Point):
 - $C_i^A \leftarrow 0$
 - $C_i^B \leftarrow 1$ → keine Oberflächenstruktur berücksichtigt (einfache Gewichtung)
- für **Point-to-Plane**:
 - $C_i^A \leftarrow 0$
 - $C_i^B \leftarrow P_i^{-1}$ → P_i ist die Projektionsmatrix auf die Ebene (beinhaltet Normalenvektor)
- für **Plane-to-Plane** (im Paper vorgeschlagene Methode):
 - `computeCovarianceMatrix` berechnet Kovarianzmatrix unter Betrachtung der nächsten 20 Punkte
 - verwendet **PCA** (Principal Component Analysis/Hauptkomponentenanalyse)

```

1  $T \leftarrow T_0$ 
2 while not converged do
3   for  $i \leftarrow 1$  to  $N$  do
4      $m_i \leftarrow \text{FindClosestPointInA}(T \cdot b_i)$ 
5      $d_i^{(T)} \leftarrow b_i - T \cdot m_i$  // Residuum / Abstand
6     if  $\|d_i^{(T)}\| \leq d_{\max}$  then
7        $C_i^A \leftarrow \text{computeCovarianceMatrix}(T \cdot b_i)$ 
8        $C_i^B \leftarrow \text{computeCovarianceMatrix}(m_i)$ 
9     else
10       $C_i^A \leftarrow 0$ ;  $C_i^B \leftarrow 0$ 
11    end
12  end
13   $T \leftarrow \arg \min_T \left\{ \sum_i d_i^{(T)^T} (C_i^B + T C_i^A T^T)^{-1} d_i^{(T)} \right\}$  // Maximum Likelihood Estimation
14 end
    
```



Abbildung 4: Plane-to-Plane (Segal et al., 2009)

Theorie - GICP-Algorithmus

Ergebnisse von Segal et al.

- GICP **genauer** bei simulierten und realen Daten
- immer noch relativ schnell und einfach
- Nutzen von Oberflächenstruktur **minimiert Einfluss von falschen Korrespondenzen**
- Parameter-Wahl für d_{\max} nicht mehr so kritisch → leichter einsetzbar in **unterschiedlichen Szenarien**



Abbildung 5: Durchschnittsfehler als Funktion von d_{\max} (Segal et al., 2009)

Demo: Eigene Implementierung in Python

- Paper sehr mathematisch
- zwar Implementierungen auf GitHub, aber nicht wirklich lesbar
- daher eigene Implementierung - vor allem für Verständnis
- eigene **2D-GICP-Funktion**
 - Input: Punktwolken A und B , ...
 - Output: Transformationsmatrix T , ...
- Version 1:
 - Visualisierung mit generierten Input-Wolken
 - iterativ durch die Steps klicken
- Version 2:
 - Simulation eines Roboters mit LiDAR-Sensor
 - Live-Berechnung der Transformation + Visualisierung

→ *LIVE DEMO*

→ *CODE OVERVIEW*

Demo: Eigene Implementierung in Python

Code Overview - GICP

GICP-Funktion:

```
def gicp(source_points, target_points, max_iterations=100, tolerance=1e-6,
        max_distance_correspondence=150, max_distance_nearest_neighbors=50):
    for iteration in range(max_iterations):
        # Calculate covariance covariance matrices for weight matrices
        # Will be used in loss function
        ...

        # Minimize the loss function
        transformation = scipy.optimize.fmin_cg(
            f=loss,
            x0=transformation,
            fprime=grad_loss)

        # Check for convergence
        if delta_loss < tolerance:
            break

    return transformation
```

Demo: Eigene Implementierung in Python

Code Overview - Roboter

GICP-Aufruf:

```
transformation_matrix = gicp(  
    _source_points,  
    _target_points,  
    max_distance_nearest_neighbors=200,  
    tolerance=1,  
)
```

Demo: Eigene Implementierung in Python

Code Overview - Roboter

Berechnung der neuen Schätzung:

```
# Get delta x, y and yaw from transformation matrix
delta_x = -transformation_matrix[0, 2]
delta_y = -transformation_matrix[1, 2]
delta_yaw = -np.arctan2(transformation_matrix[1, 0], transformation_matrix[0, 0])

# Calculate estimations for new position and orientation
new_estimated_x = last_estimated_x
    + delta_x * math.cos(last_estimated_yaw)
    - delta_y * math.sin(last_estimated_yaw)

new_estimated_y = last_estimated_y
    + delta_x * math.sin(last_estimated_yaw)
    + delta_y * math.cos(last_estimated_yaw)

new_estimated_yaw = last_estimated_yaw + delta_yaw
```

Implementierung in ROS - Versuch

Leitfrage

Ist Generalized-ICP besser als Standard-ICP und wie verhält sich der Algorithmus in unterschiedlichen Szenarien?

Implementierung in ROS - Versuch

Versuchsaufbau

- Vorbedingungen:
 - Bag File
 - Skript für Nodes
 - Yaml files als configuration
- Szenarien:
 - Drei unterschiedliche Maps
 - Unterschiedliche Parameterisierung
 - Fünf Durchgänge mit Standardparameterisierung (ICP & GICP)
- Auswertung:
 - Bag Files mit Topics
 - Python-Skript zur Auswertung
 - Bokeh für Visualisierung

Implementierung in ROS - Versuch

Parameterisierung

```
//name des odom topics
this->declare_parameter("odom_topic", "");
//name des icp topics
this->declare_parameter("gicp_result_topic", "");
//name des zeitmessung topics
this->declare_parameter("alignment_time_topic", "");
//parameter ob gicp oder icp verwendet wird
this->declare_parameter("gicp", false);
//ob manuelle transformation gepublished wird
this->declare_parameter("publish_tf", false);

//icp parameter
this->declare_parameter("max_correspondence_distance", 0.0);
this->declare_parameter("maximum_iterations", 0);
this->declare_parameter("transformation_epsilon", 0.0);
this->declare_parameter("euclidean_fitness_epsilon", 0.0);
```

Implementierung in ROS - Versuch

Parameterisierung über YAML file

```
gicp_lio:
  ros__parameters:
    gicp: True
    publish_tf: False
    alignment_time_topic: "galignment_time"
    odom_topic: "glidar_odom"
    gicp_result_topic: "glidar_odom_eval"
    max_correspondence_distance: 0.2
    maximum_iterations: 100
    transformation_epsilon: 0.000000001
    euclidean_fitness_epsilon: 0.00001
```

```
gicp_lio:
  ros__parameters:
    gicp: False
    publish_tf: False
    alignment_time_topic: "alignment_time"
    odom_topic: "lidar_odom"
    gicp_result_topic: "lidar_odom_eval"
    max_correspondence_distance: 0.2
    maximum_iterations: 100
    transformation_epsilon: 0.000000001
    euclidean_fitness_epsilon: 0.00001
```

Implementierung in ROS - Versuch

Implementierung ICP & GICP

- ICP:

```
pcl::IterativeClosestPoint<pcl::PointXYZ, pcl::PointXYZ> icp;  
icp.setInputSource(src);  
icp.setInputTarget(tgt);  
pcl::PointCloud<pcl::PointXYZ>::Ptr output(new pcl::PointCloud<pcl::PointXYZ>);  
icp.align(*output);
```

- GICP:

```
pcl::GeneralizedIterativeClosestPoint<pcl::PointXYZ, pcl::PointXYZ> gicp;  
gicp.setInputSource(src);  
gicp.setInputTarget(tgt);  
pcl::PointCloud<pcl::PointXYZ>::Ptr output(new pcl::PointCloud<pcl::PointXYZ>);  
gicp.align(*output);
```

Implementierung in ROS - Versuch

Zeitmessung

```
auto start = std::chrono::high_resolution_clock::now();
icp.align(*output);
transformation = icp.getFinalTransformation();
auto finish = std::chrono::high_resolution_clock::now();

std::chrono::duration<double> elapsed = finish - start;
std_msgs::msg::Float64 time_msg;
time_msg.data = elapsed.count();
time_publisher_ -> publish(time_msg);
```

Implementierung in ROS - Versuch

Problem: Aufsummierende Fehler

```
// reduce tick speed in topic_callback
tick++;
if (tick % 3 != 0) {
    return;
}
```




Abbildung 6: Trajectory plot with higher tick speed




Abbildung 7: Trajectory plot with lower tick speed

Implementierung in ROS - Versuch

Turtlebot3 World




Abbildung 8: Screenshot Gazebo

Implementierung in ROS - Versuch

Turtlebot3 World




Abbildung 9: Screenshot Gazebo

Implementierung in ROS - Versuch

Turtlebot3 ICP World







Abbildung 10: Screenshot Gazebo



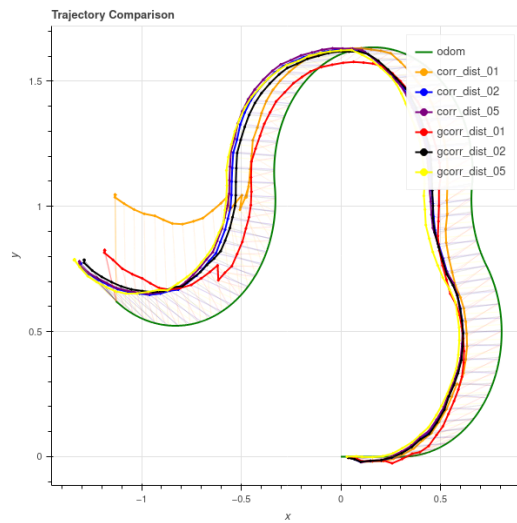
Auswertung

Drei unterschiedliche Maps




Auswertung

Unterschiedliche Parameterisierung



Auswertung

Fünf Durchgänge mit Standardparameterisierung (ICP & GICP)



Fazit

- Leitfrage: Ist Generalized-ICP besser als Standard-ICP und wie verhält sich der Algorithmus in unterschiedlichen Szenarien?
- keine deutlich besseren Ergebnisse bei GICP
- Parameter-Wahl nicht so kritisch wie bei ICP kann bestätigt werden
- keine marginalen Unterschiede zwischen ICP & GICP in den unterschiedlichen Maps
- GICP ist aufwendiger in der Berechnung
- Abhängigkeit von der Simulationsumgebung
- Unterschiede zu Paper, da 3D-Scan und deutlich mehr Punkte

(Bild-)Quellen

Igor Bogoslavskyi. (2021). <https://nbviewer.org/github/niosus/notebooks/blob/master/icp.ipynb>

Intelligent Data Analysis and Probabilistic Inference Lecture 14. (2018).

Kok-Lim Low. (2004). *Linear Least-Squares Optimization for Point-to-Plane ICP Surface Registration.*

https://www.comp.nus.edu.sg/~lowkl/publications/lowk_point-to-plane_icp_techrep.pdf

Segal, A. V., Hähnel, D., & Thrun, S. (2009). Generalized-ICP. *Robotics: Science and Systems*. <https://api.semanticscholar.org/CorpusID:231748613>

Anhang - Bestimmung der Kovarianzmatrizen bei Plane-to-Plane GICP

```
covariance_ground = np.array([[epsilon, 0], [0, 1]])
covariance = np.cov(neighbors, rowvar=False)
eigenvalues, eigenvectors = np.linalg.eig(covariance)
ev = eigenvectors[:, np.argmax(eigenvalues)] # vector with highest eigenvalue
rotation_matrix = np.array([[ev[0], -ev[1]], [ev[1], ev[0]]])
covariance_aligned = rotation_matrix @ covariance_ground @ rotation_matrix.T
```

- nicht einfach die Kovarianzmatrix der Nachbars-Punkte
- normalisiert
- Kovarianzmatrix für die Ebene erstellt: $\begin{pmatrix} \varepsilon & 0 \\ 0 & 1 \end{pmatrix}$
 - ε ist ein kleiner Wert
- Lage der Punkte im Raum betrachtet
 - Hauptkomponentenanalyse (Eigenvektoren und Eigenwerte)
 - Eigenvektor mit höchstem Eigenwert
- Einheits-Kovarianzmatrix wird um die Lage der Punkte im Raum gedreht




Abbildung 11: Eigenvektoren spiegeln die Lage der Punkte im Raum wider (*Intelligent Data Analysis and Probabilistic Inference Lecture 14, 2018*)