

Generalized Iterative Closest Point

Mündliche Prüfung in der Vorlesung Autonome Roboter

bei Prof. Dr.-Ing. Michael Blaich

16.07.2024

Johannes Brandenburger, Moritz Kaltenstadler, Fabian Klimpel

Agenda

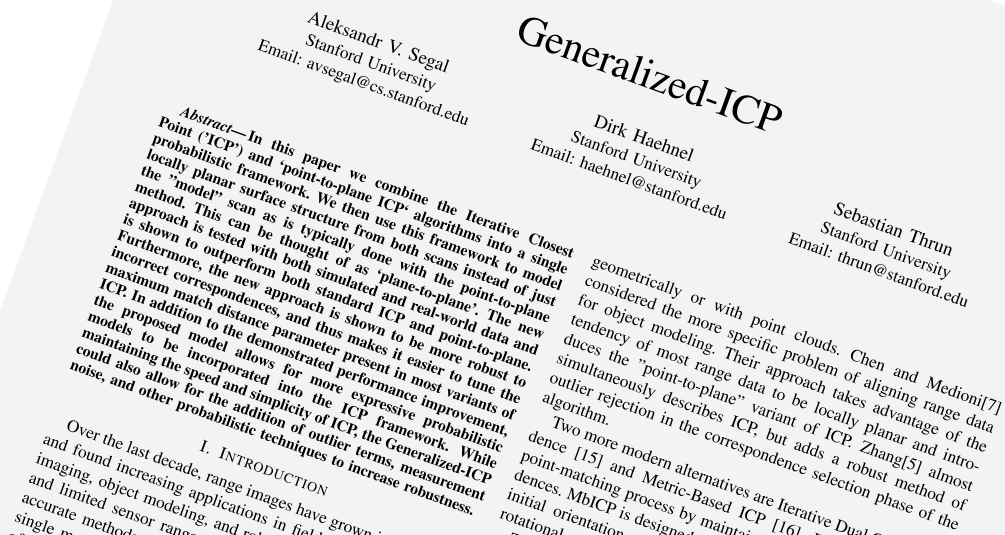
1. Einführung
2. Theorie
 1. Mathematische Grundlagen
 2. Standard-ICP
 3. Point-to-Plane-ICP
 4. Generalized-ICP
 5. Ergebnisse von Segal et al.
3. Demo: Eigene Implementierung in Python
4. Implementierung in ROS
 1. Parameterisierung
 2. Problem
 3. Implementierung

Kommentar

Test

Einführung

- ICP: **Iterative Closest Point**
 - Scan-Matching-Algorithmus
 - Schätzung der Transformation zwischen zwei Punktwolken
 - Anwendung in der Lokalisierung mit z.B. LiDAR-Sensoren
- GICP: **Generalized-ICP**
 - veröffentlicht von Segal, Haehnel & Thrun (2009)
 - Stanford University
 - Ziel: ICP-Algorithmus verbessern und verallgemeinern
 - Standard-ICP & point-to-plane in **generelles Framework** überführen
 - **probabilistische** Betrachtung
 - Nutzung **Oberflächenstruktur** aus beiden Scans (Kovarianzmatrizen) → **plane-to-plane**



Kommentar

- ICP Verfahren schon in Vorlesung
- grober Überblick
- ICP steht für Iterative Closest Point
- Scan-Matching-Algorithmus
- Schätzung der Transformation zwischen zwei Punktwolken
- Anwendung in der Lokalisierung mit z.B. LiDAR-Sensoren
- wurde 2009 von Segal, Haehnel & Thrun verbessert
- an Stanford University Verfahren entwickelt
- Generalized-ICP
- Ziel: ICP-Algorithmus verbessern und verallgemeinern
 - Probleme Standard-ICP:
 - nicht sehr robust
 - sehr empfindlich gegenüber der Parameterwahl
 - daher schlecht in mehreren Szenarien einsetzbar
 - Standard-ICP ist für Punktwolken in einer gemeinsamen Koordinatenachse zu führen
 - Wählbar, weil es sich um ein Problem handelt, das im Rahmen der mathematischen Grundlagen

Theorie - Mathematische Grundlagen

Kovarianzmatrix

- beschreibt die Streuung von Zufallsvariablen
- für Punkte in Punktwolken: Verteilung der Punkte in der Umgebung

Maximum Likelihood Estimation (MLE)

- Schätzverfahren für Parameter von Wahrscheinlichkeitsverteilungen
- der Parameter wird ausgewählt, der die beobachteten Daten am wahrscheinlichsten macht
- oft verwendet um: $\arg \max_p \dots / \arg \min_p \dots$ zu finden

Kommentar

- Mathematische Grundlagen sind lediglich für ein gemeinsames Verständnis
- sodass auch Leute, die nicht die Vorlesung besucht haben, den Vortrag verstehen könnten
- Kovarianzmatrix beschreibt die Streuung von Zufallsvariablen
- in unserem Kontext: Verteilung von Punkte in der Umgebung
- wo unsere Punkte mit welcher Wahrscheinlichkeit liegen
- Maximum Likelihood Estimation brauchen wir für die Schätzung der Transformation bei ICP und GICP
- Schätzverfahren für Parameter von Wahrscheinlichkeitsverteilungen
- versucht quasi die Parameter zu finden, die eine gegebene Wahrscheinlichkeitsverteilung am besten beschreiben

Theorie - Standard-ICP

- **Iterative Closest Point** (ICP) ist ein Algorithmus, um die Transformation zwischen zwei Punktwolken zu schätzen
- vergleicht korrespondierende Punkte in beiden Wolken
- minimiert die quadratischen Abstände korrespondierender Punkte

```
1  $T \leftarrow T_0$ 
2 while not converged do
3   for  $i \leftarrow 1$  to  $N$  do
4      $m_i \leftarrow \text{FindClosestPointInA}(T \cdot b_i)$ 
5     if  $\|m_i - b_i\| \leq d_{\max}$  then
6        $w_i \leftarrow 1$ 
7     else
8        $w_i \leftarrow 0$ 
9     end
10  end
11   $T \leftarrow \arg \min_T \left\{ \sum_i w_i (\|T \cdot b_i - m_i\|)^2 \right\}$ 
12 end
```




Abbildung 1: Standard-ICP (Igor Bogoslavskyi, 2021)

Kommentar

- wie schon gesagt: Standard ICP lässt uns Transformation zwischen zwei Punktwolken schätzen
- dabei ist er sehr einfach und schnell
- vergleicht korrespondierende Punkte in beiden Wolken
- minimiert die quadratischen Abstände korrespondierender Punkte
- schätzt so die Transformation
- in Pseudocode dargestellt
- Startwert für Transformation T_0
 - kann bereits eine sinnvolle Schätzung sein (z.b. Odometrie)
- Loop bis der Algorithmus konvergiert (daher auch „Iterative“)
- für jeden Punkt in der Quellwolke b_i wird der nächste Punkt in der Zielwolke A gesucht
- dann wird geschaut ob der Abstand kleiner als das Threshold d_{\max} ist
 - Parameter steuert also, welche Punkte berücksichtigt werden und welche nicht
 - ist je nach Anwendungsszenario unterschiedlich
 - wenn Roboter schneller fährt, dann muss d_{\max} größer sein
 - schwierig einzustellen
- Punkt wird gewichtet, oder nicht
- am Ende jedes Durchlaufs wird die Transformation berechnet
 - so dass die quadratischen Abstände minimiert werden
 - durch Veränderung der Transformationsparameter

Theorie - Point-to-Plane-ICP

- **Point to Plane ICP** ist eine Erweiterung des ICP Algorithmus
- vergleicht korrespondierende Punkte in einer Wolke zu Ebenen in der anderen
- Ebenen wird durch Punkt und Normalenvektor definiert

$$T \leftarrow \arg \min_T \left\{ \sum_i ((T \cdot b_i - m_i) \cdot \mathbf{n}_i)^2 \right\}$$




Abbildung 2: Point-to-Plane-ICP (Kok-Lim Low, 2004)

Kommentar

- Point-to-Plane-ICP ist eine Erweiterung des Standard-ICP
- Standard-ICP betrachtet keine Oberflächenstruktur
 - bei Laserscan zum Beispiel:
 - wenn 2 mal eine Wand gescant
 - Punkte zwar durch die Abtastrate unterschiedlichen Stellen im Raum
 - kann sein, dass die Bewegung zur Wand nicht wirklich groß war
- um dies entgegenzuwirken, vergleicht Point-to-Plane-ICP Punkte in einer Wolke zu Ebenen in der anderen
- Ebenen wird durch Punkt und Normalenvektor definiert
- Optimierungsfunktion in der letzten Zeile des Algorithmus:
 - minimiert quadratische Abstände zwischen Punkt und Ebene

Theorie - Standard-ICP, Point-to-Plane, Generalized-ICP

- **Point-to-Point**
 - Standard-ICP
 - vergleicht Punkt mit Punkt
- **Point-to-Plane**
 - vergleicht Punkt mit Ebene durch Normalenvektor
- **Generalized-ICP**
 - quasi „Plane-to-Plane“
 - vergleicht die Kovarianzmatrizen der nächsten Punkte → probabilistisch
 - wenn in Ebene → Kovarianzmatrix ist „flach“




Abbildung 3: Kovarianzmatrizen (eigene Darstellung)

Kommentar

- hier nochmal ein Überblick über die verschiedenen ICP-Verfahren
- Point-to-Point: Standard-ICP
 - vergleicht Punkt mit Punkt
 - einfach und schnell
 - aber nicht robust sehr empfindlich gegenüber Parameterwahl
- Point-to-Plane:
 - vergleicht Punkt mit Ebene durch Normalenvektor
 - besser als Standard-ICP
 - nutzt Oberflächenstruktur einer Punktwolke
 - aber eben nur von einer
- Generalized-ICP:
 - quasi „Plane-to-Plane“
 - vergleicht die Kovarianzmatrizen der nächsten Punkte → probabilistisch
 - wenn in Ebene → Kovarianzmatrix ist „flach“
 - sieht man in Bild rechts
 - nutzt Oberflächenstruktur beider Punktwolken
 - welche Ergebnisse dies hat, dazu später mehr

Theorie - GICP-Algorithmus

```
1  $T \leftarrow T_0$ 
2 while not converged do
3   for  $i \leftarrow 1$  to  $N$  do
4      $m_i \leftarrow \text{FindClosestPointInA}(T \cdot b_i)$ 
5      $d_i^{(T)} \leftarrow b_i - T \cdot m_i$            // Residuum / Abstand
6     if  $\| d_i^{(T)} \| \leq d_{\max}$  then
7        $C_i^A \leftarrow \text{computeCovarianceMatrix}(T \cdot b_i)$ 
8        $C_i^B \leftarrow \text{computeCovarianceMatrix}(m_i)$ 
9     else
10       $C_i^A \leftarrow 0$ ;  $C_i^B \leftarrow 0$ 
11    end
12  end
13   $T \leftarrow \arg \min_T \left\{ \sum_i d_i^{(T)^T} (C_i^B + T C_i^A T^T)^{-1} d_i^{(T)} \right\}$  // Maximum Likelihood Estimation
14 end
```

Kommentar

- im Paper wurde Algorithmus nie zusammenhängend dargestellt
 - deshalb hier nochmals selber zusammengebaut
- Anfang des Algorithmus gleich wie bei Standard-ICP
- statt Gewichtung mit 0 oder 1 werden Kovarianzmatrizen verwendet
 - wie genau diese berechnet bzw gewählt werden, dazu mehr auf der nächsten Folie
- Minimierungsfunktion am Ende des Schleifendurchlaufs anders
 - nutzt Gewichtungsmatrix, die aus den Kovarianzmatrizen berechnet wird
 - mittlere Teil der Minimierungsfunktion
- im Paper wird für die Optimierung der Transformation also für $\arg \min$ Maximum Likelihood Estimation verwendet
 - wählt Transformationsmatrix T so dass die Verteilung am wahrscheinlichsten ist

Theorie - GICP-Algorithmus

Variationen für Kovarianzmatrizen

$$C_i^A \leftarrow \text{computeCovarianceMatrix}(T \cdot b_i)$$

$$C_i^B \leftarrow \text{computeCovarianceMatrix}(m_i)$$

- für **Standard-ICP** (Point-to-Point):
 - $C_i^A \leftarrow 0$
 - $C_i^B \leftarrow 1 \rightarrow$ keine Oberflächenstruktur berücksichtigt (einfache Gewichtung)
- für **Point-to-Plane**:
 - $C_i^A \leftarrow 0$
 - $C_i^B \leftarrow P_i^{-1} \rightarrow P_i$ ist die Projektionsmatrix auf die Ebene (beinhaltet Normalenvektor)
- für **plane-to-plane** (im Paper vorgeschlagene Methode):
 - `computeCovarianceMatrix` berechnet Kovarianzmatrix unter Betrachtung der nächsten 20 Punkte
 - verwendet **PCA** (Principal Component Analysis/Hauptkomponentenanalyse)




Abbildung 4: Plane-to-plane (Segal et al., 2009)

Theorie - GICP-Algorithmus

Ergebnisse von Segal et al.

- GICP **genauer** bei simulierten und realen Daten
- immer noch relativ schnell und einfach
- Nutzen von Oberflächenstruktur **minimiert Einfluss von falschen Korrespondenzen**
- Parameter-Wahl für d_{\max} nicht mehr so kritisch → leichter einsetzbar in **unterschiedlichen Szenarien**




Abbildung 5: Durchschnittsfehler als Funktion von d_{\max} (Segal et al., 2009)

Demo: Eigene Implementierung in Python

- Paper sehr mathematisch
- zwar Implementierungen auf GitHub, aber nicht wirklich lesbar
- daher eigene Implementierung - vor allem für Verständnis
- eigene **2D-GICP-Funktion**
 - Input: Punktwolken A und B , ...
 - Output: Transformationsmatrix T , ...
- Version 1:
 - Visualisierung mit generierten Input-Wolken
 - iterativ durch die Steps klicken
- Version 2:
 - Simulation eines Roboters mit LiDAR-Sensor
 - Live-Berechnung der Transformation + Visualisierung

→ *LIVE DEMO*

→ *CODE OVERVIEW*

Parameterisierung

```
//name des odom topics
this->declare_parameter("odom_topic", "");
//name des icp topics
this->declare_parameter("gicp_result_topic", "");
//name des zeitmessung topics
this->declare_parameter("alignment_time_topic", "");
//parameter ob gicp oder icp verwendet wird
this->declare_parameter("gicp", false);
//ob manuelle transformation gepublished wird
this->declare_parameter("publish_tf", false);

//icp parameter
this->declare_parameter("max_correspondence_distance", 0.0);
this->declare_parameter("maximum_iterations", 0);
this->declare_parameter("transformation_epsilon", 0.0);
this->declare_parameter("euclidean_fitness_epsilon", 0.0);
```

Parameterisierung über YAML file

```
gicp_lio:
  ros__parameters:
    gicp: True
    publish_tf: False
    alignment_time_topic: "galignment_time"
    odom_topic: "glidar_odom"
    gicp_result_topic: "glidar_odom_eval"
    max_correspondence_distance: 0.2
    maximum_iterations: 100
    transformation_epsilon: 0.000000001
    euclidean_fitness_epsilon: 0.00001
```

```
gicp_lio:
  ros__parameters:
    gicp: False
    publish_tf: False
    alignment_time_topic: "alignment_time"
    odom_topic: "lidar_odom"
    gicp_result_topic: "lidar_odom_eval"
    max_correspondence_distance: 0.2
    maximum_iterations: 100
    transformation_epsilon: 0.000000001
    euclidean_fitness_epsilon: 0.00001
```

Implementierung in Ros

- ICP:

```
pcl::IterativeClosestPoint<pcl::PointXYZ, pcl::PointXYZ> icp;  
icp.setInputSource(src);  
icp.setInputTarget(tgt);  
pcl::PointCloud<pcl::PointXYZ>::Ptr output(new pcl::PointCloud<pcl::PointXYZ>);  
icp.align(*output);
```

- GICP:

```
pcl::GeneralizedIterativeClosestPoint<pcl::PointXYZ, pcl::PointXYZ> gicp;  
gicp.setInputSource(src);  
gicp.setInputTarget(tgt);  
pcl::PointCloud<pcl::PointXYZ>::Ptr output(new pcl::PointCloud<pcl::PointXYZ>);  
gicp.align(*output);
```

Implementierung in Ros - Problem

```
// reduce tick speed in topic_callback  
tick++;  
if (tick % 3 != 0) {  
    return;  
}
```




Abbildung 6: Trajectory plot with higher tick speed




Abbildung 7: Trajectory plot with lower tick speed

Implementierung in Ros

```
auto start = std::chrono::high_resolution_clock::now();
icp.align(*output);
transformation = icp.getFinalTransformation();
auto finish = std::chrono::high_resolution_clock::now();

std::chrono::duration<double> elapsed = finish - start;
std_msgs::msg::Float64 time_msg;
time_msg.data = elapsed.count();
time_publisher->publish(time_msg);
```

3 unterschiedliche Maps

- jeweils Bild reinmachen
- roboter war immer der gleiche

Versuchsaufbau

- fünf Durchgänge mit Standardparameterisierung (ICP & GICP)
- drei unterschiedliche Maps
- unterschiedliche Parameterisierung

Turtlebot3 World




Abbildung 8: Screenshot Gazebo

Turtlebot3 ICP World




Abbildung 9: Screenshot Gazebo

Turtlebot3 World




Abbildung 10: Screenshot Gazebo

(Bild-)Quellen

Igor Bogoslavskyi. (2021). <https://nbviewer.org/github/niosus/notebooks/blob/master/icp.ipynb>

Kok-Lim Low. (2004). *Linear Least-Squares Optimization for Point-to-Plane ICP Surface Registration*.
https://www.comp.nus.edu.sg/~lowkl/publications/lowk_point-to-plane_icp_techrep.pdf

Segal, A. V., Hähnel, D., & Thrun, S. (2009). Generalized-ICP. *Robotics: Science and Systems*. <https://api.semanticscholar.org/CorpusID:231748613>