Generalized Iterative Closest Point

Mündliche Prüfung in der Vorlesung Autonome Roboter

bei Prof. Dr.-Ing. Michael Blaich

17.07.2024

Johannes Brandenburger, Moritz Kaltenstadler, Fabian Klimpel

Agenda

1. Einführung
2. Theorie
    1. Mathematische Grundlagen
    2. Standard-ICP
    3. Point-to-Plane-ICP
    4. Generalized-ICP
    5. Ergebnisse von Segal et al.
3. Demo: Eigene Implementierung in Python
4. Implementierung in ROS - Versuch
    1. Versuchsaufbau
    2. Parameterisierung
    3. Implementierung ICP & GICP
    4. Problem
    5. Zeitmessung
    6. Maps
5. Auswertung
6. Fazit
7. (Bild-)Quellen

Einführung

- ICP: **Iterative Closest Point**
  - Scan-Matching-Algorithmus
  - Schätzung der Transformation zwischen zwei Punktwolken
  - Anwendung in der Lokalisierung mit z.B. LiDAR-Sensoren

- GICP: **Generalized-ICP**
  - veröffentlicht von Segal, Haehnel & Thrun (2009)
  - Stanford University
  - Ziel: ICP-Algorithmus verbessern und verallgemeinern
  - Standard-ICP & point-to-plane in **generelles Framework** überführen
  - **probabilistische** Betrachtung
  - Nutzung **Oberflächenstruktur** aus beiden Scans (Kovarianzmatrizen) → **plane-to-plane**

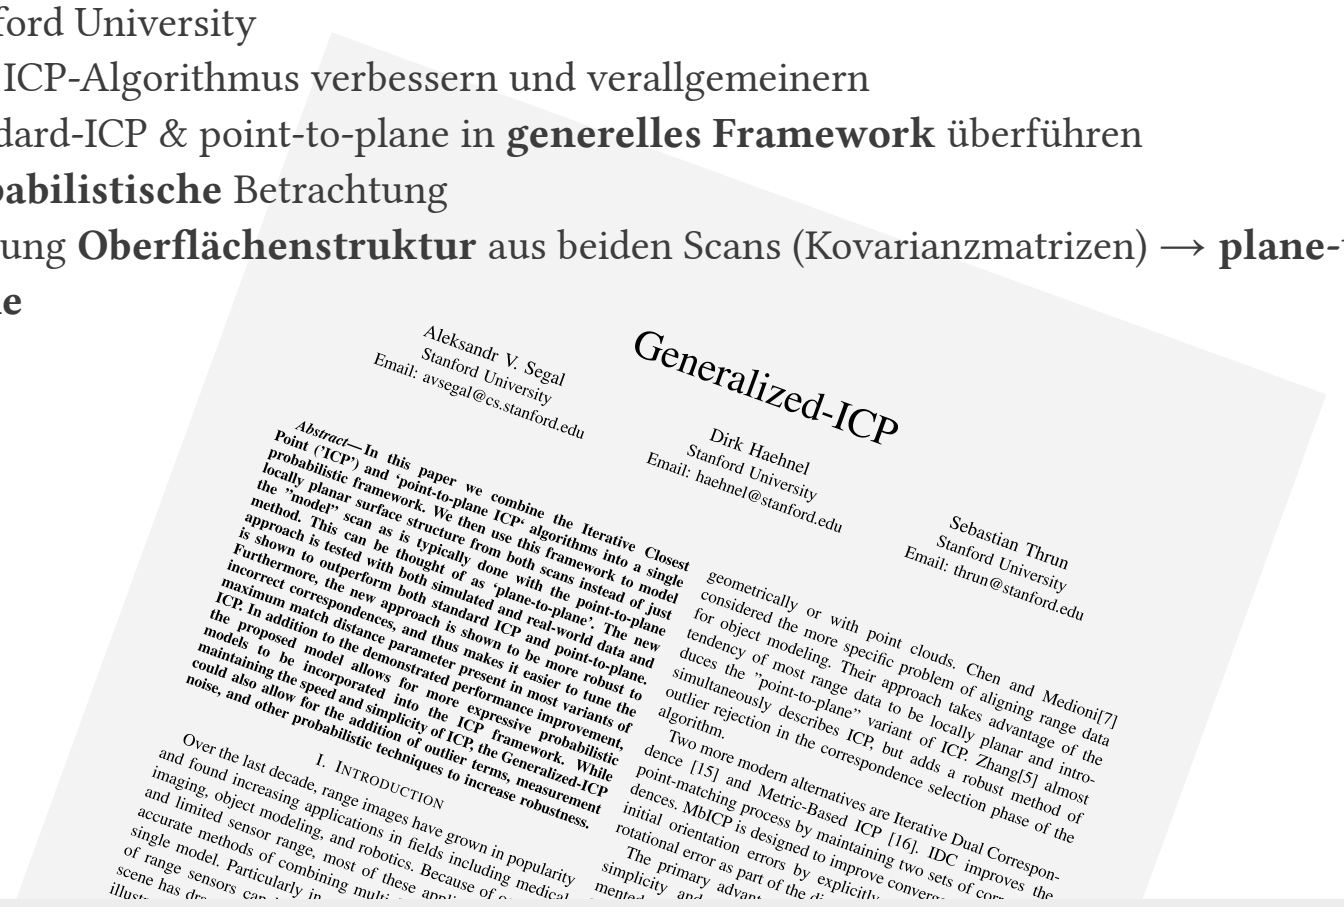

Generalized-ICP

Aleksandr V. Segal
Stanford University
Email: avsegal@cs.stanford.edu

Dirk Haehnel
Stanford University
Email: haehnel@stanford.edu

Sebastian Thrun
Stanford University
Email: thrun@stanford.edu

***Abstract*— In this paper we combine the Iterative Closest Point ('ICP') and 'point-to-plane ICP' algorithms into a single probabilistic framework. We then use this framework to model locally planar surface structure from both scans instead of just the "model" scan as is typically done with the point-to-plane method. This can be thought of as 'plane-to-plane'. The new approach is tested with both simulated and real-world data and is shown to outperform both standard ICP and point-to-plane. Furthermore, the new approach is shown to be more robust to incorrect correspondences, and thus makes it easier to tune the maximum match distance parameter present in most variants of ICP. In addition to the demonstrated performance improvement, the proposed model allows for more expressive probabilistic models to be incorporated into the ICP framework. While maintaining the speed and simplicity of ICP, the Generalized-ICP could also allow for the addition of outlier terms, measurement noise, and other probabilistic techniques to increase robustness.**

I. Introduction

Over the last decade, range images have grown in popularity and found increasing applications in fields including medical imaging, object modeling, and robotics. Because of ... limited sensor range, most of these ... accurate methods of combining ... single model. Particularly in ... of range sensors can ... scene has ... illust...

geometrically or with point clouds. Chen and Medioni[7] considered the more specific problem of aligning range data for object modeling. Their approach takes advantage of the tendency of most range data to be locally planar and introduces the "point-to-plane" variant of ICP. Zhang[5] almost simultaneously describes ICP, but adds a robust method of outlier rejection in the correspondence selection phase of the algorithm.

Two more modern alternatives are Iterative Dual Correspondence [15] and Metric-Based ICP [16]. IDC improves the point-matching process by maintaining two sets of correspondences. MbICP is designed to improve convergence ... initial orientation errors by explicitly ... rotational error as part of the ... The primary advant... simplicity and ... mented...

Speaker Notes

- ICP Verfahren schon in Vorlesung
- grober Überblick
- ICP steht für Iterative Closest Point
- Scan-Matching-Algorithmus
- Schätzung der Transformation zwischen zwei Punktwolken
- Anwendung in der Lokalisierung mit z.B. LiDAR-Sensoren
- wurde 2009 von Segal, Haehnel & Thrun verbessert
- an Stanford University Verfahren entwickelt
- Generalized-ICP
- Ziel: ICP-Algorithmus verbessern und verallgemeinern
  -

  Probleme Standard-ICP:
  - nicht sehr robust
  - sehr empfindlich gegenüber der Parameterwahl
  - daher schlecht in mehreren Szenarien einsetzbar
- Standard-ICP & point-to-plane in generelles Framework überführen
- 2 große Änderungen:
  - Wahrscheinlichkeitstheorie
  - Nutzung planarer Strukturen
    - Punktwolke sind nicht random im Raum verteilt
    - haben Struktur zb von Wänden
    - GICP nutzt diese Struktur in Form von Kovarianzmatrizen
      - Überleitung Kovarianzmatrizen -> Mathematische Grundlagen

Theorie - Mathematische Grundlagen

Kovarianzmatrix

- beschreibt die Streuung von Zufallsvariablen
- für Punkte in Punktwolken: Verteilung der Punkte in der Umgebung

Maximum Likelihood Estimation (MLE)

- Schätzverfahren für Parameter von Wahrscheinlichkeitsverteilungen
- der Parameter wird ausgewählt, der die beobachteten Daten am wahrscheinlichsten macht
- oft verwendet um: $\arg\max_p \ldots$ / $\arg\min_p \ldots$ zu finden

Speaker Notes

- Mathematische Grundlagen sind lediglich für ein gemeinsames Verständnis
- sodass auch Leute, die nicht die Vorlesung besucht haben, den Vortrag verstehen könnten
- Kovarianzmatrix beschreibt die Streuung von Zufallsvariablen
- in unserem Kontext: Verteilung von Punkte in der Umgebung
- wo unsere Punkte mit welcher Wahrscheinlichkeit liegen
- Maximum Likelihood Estimation brauchen wir für die Schätzung der Transformation bei ICP und GICP
- Schätzverfahren für Parameter von Wahrscheinlichkeitsverteilungen
- versucht quasi die Parameter zu finden, die eine gegebene Wahrscheinlichkeitsverteilung am besten beschreiben

Theorie - Standard-ICP

- **Iterative Closest Point** (ICP) ist ein Algorithmus, um die Transformation zwischen zwei Punktwolken zu schätzen
- vergleicht korrespondierende Punkte in beiden Wolken
- minimiert die quadratischen Abstände korrespondierender Punkte

```
1  T ← T_0
2  while not converged do
3  |  for i ← 1 to N do
4  |  |  m_i ← FindClosestPointInA(T · b_i)
5  |  |  if ‖ m_i − b_i ‖≤ d_max then
6  |  |  |  w_i ← 1
7  |  |  else
8  |  |  |  w_i ← 0
9  |  |  end
10 |  end
11 |  T ← arg min_T { Σ_i w_i (‖ T · b_i − m_i ‖)^2 }
12 end
```

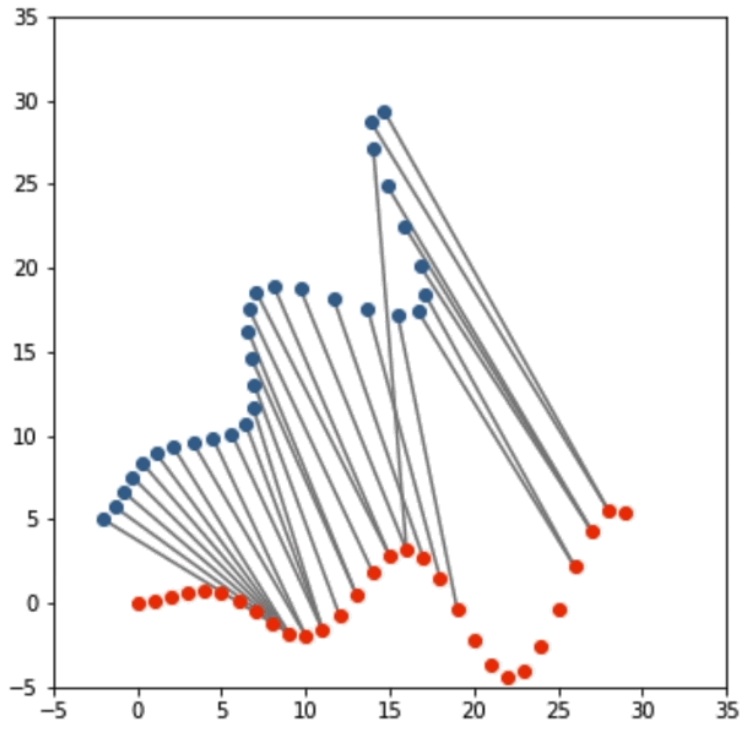

Abbildung 1: Standard-ICP (Igor Bogoslavskyi, 2021)

Speaker Notes

- wie schon gesagt: Standard ICP lässt uns Transformation zwischen zwei Punktwolken schätzen
- dabei ist er sehr einfach und schnell
- vergleicht korrespondierende Punkte in beiden Wolken
- minimiert die quadratischen Abstände korrespondierender Punkte
- schätzt so die Transformation
- in Pseudocode dargestellt
- Startwert für Transformation T_0
  - kann bereits eine sinnvolle Schätzung sein (z.b. Odometrie)
- Loop bis der Algorithmus konvergiert (daher auch „Iterative“)
- für jeden Punkt in der Sourcewolke b_i wird der nächste Punkt in der Targetwolke A gesucht
- dann wird geschaut ob der Abstand kleiner als das Threshold $d_{\max}$ ist
  - Parameter steuert also, welche Punkte berücksichtigt werden und welche nicht
  - ist je nach Anwendungsszenario unterschiedlich
    - wenn Roboter schneller fährt, dann muss $d_{\max}$ größer sein
    - schwierig einzustellen
- Punkt wird gewichtet, oder nicht
- am Ende jedes Durchlaufs wird die Transformation berechnet
  - durch Veränderung der Transformationsparameter
  - so dass die quadratischen Abstände minimiert werden

Theorie - Point-to-Plane-ICP

- **Point to Plane ICP** ist eine Erweiterung des ICP Algorithmus
- vergleicht korrespondierende Punkte in einer Wolke zu Ebenen in der anderen
- Ebenen wird durch Punkt und Normalenvektor definiert

$$T \leftarrow \arg\min_T \left\{ \sum_i \left((T \cdot b_i - m_i) \cdot \boldsymbol{n_i} \right)^2 \right\}$$

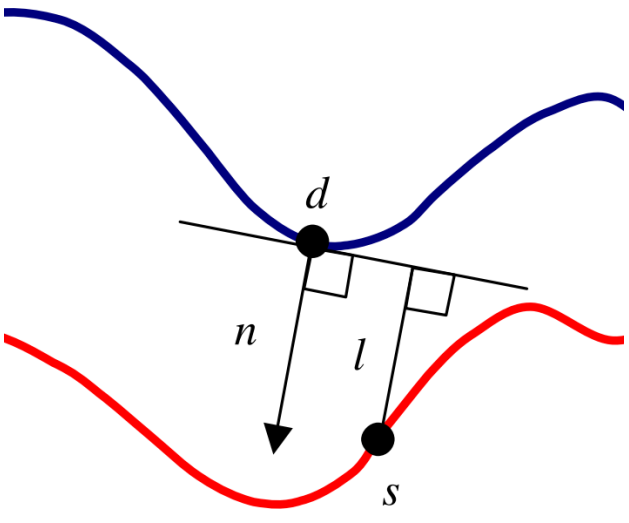

Abbildung 2: Point-to-Plane-ICP (Kok-Lim Low, 2004)

Speaker Notes

- Point-to-Plane-ICP ist eine Erweiterung des Standard-ICP
- Standard-ICP betrachtet keine Oberflächenstruktur
  - bei Laserscan zum Beispiel:
    - wenn 2 mal eine Wand gescant
    - Punkte zwar durch die Abtastrate unterschiedlichen Stellen im Raum
    - kann sein, dass die Bewegung zur Wand nicht wirklich groß war
- um dem entgegenzuwirken, vergleicht Point-to-Plane-ICP Punkte in einer Wolke zu Ebenen in der anderen
- Ebenen wird durch Punkt und Normalenvektor definiert
- Optimierungsfunktion in der letzten Zeile des Algorithmus:
  - minimiert quadratische Abstände zwischen Punkt und Ebene

Theorie - Standard-ICP, Point-to-Plane, Generalized-ICP

- **Point-to-Point**
  - Standard-ICP
  - vergleicht Punkt mit Punkt
- **Point-to-Plane**
  - vergleicht Punkt mit Ebene durch Normalenvektor
- **Generalized-ICP**
  - quasi „Plane-to-Plane“
  - vergleicht die Kovarianzmatrizen der nächsten Punkte ⟶ probabilistisch
  - wenn in Ebene ⟶ Kovarianzmatrix ist „flach“

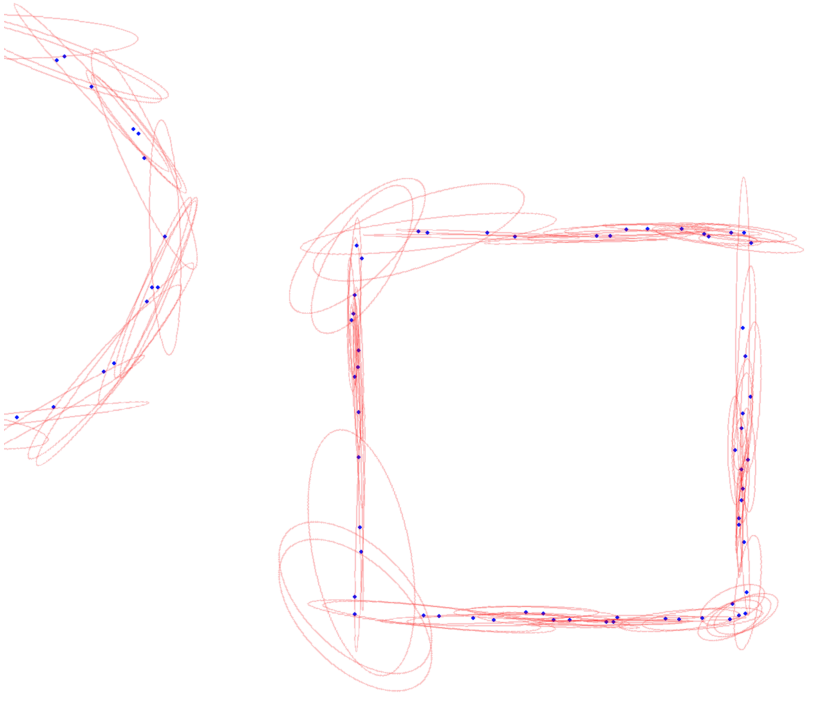

Abbildung 3: Kovarianzmatrizen (eigene Darstellung)

Speaker Notes

- hier nochmal ein Überblick über die verschiedenen ICP-Verfahren
- Point-to-Point: Standard-ICP
  - vergleicht Punkt mit Punkt
  - einfach und schnell
  - aber nicht robust sehr empfindlich gegenüber Parameterwahl
- Point-to-Plane:
  - vergleicht Punkt mit Ebene durch Normalenvektor
  - besser als Standard-ICP
  - nutzt Oberflächenstruktur einer Punktwolke
  - aber eben nur von einer
- Generalized-ICP:
  - quasi „Plane-to-Plane“
  - vergleicht die Kovarianzmatrizen der nächsten Punkte ⟶ probabilistisch
  - wenn in Ebene ⟶ Kovarianzmatrix ist „flach“
    - sieht man in Bild rechts
  - nutzt Oberflächenstruktur beider Punktwolken
  - welche Ergebnisse dies hat, dazu später mehr

Theorie - GICP-Algorithmus

$T \leftarrow T_0$
while not converged **do**
  for $i \leftarrow 1$ **to** N **do**
    $m_i \leftarrow \texttt{FindClosestPointInA}(T \cdot b_i)$
    $d_i^{(T)} \leftarrow b_i - T \cdot m_i$ // Residuum / Abstand
    if $\| d_i^{(T)} \| \leq d_{\max}$ **then**
      $C_i^A \leftarrow \texttt{computeCovarianceMatrix}(T \cdot b_i)$
      $C_i^B \leftarrow \texttt{computeCovarianceMatrix}(m_i)$
    else
      $C_i^A \leftarrow 0; \quad C_i^B \leftarrow 0$
    end
  end
  $T \leftarrow \arg\min_T \left\{ \sum_i {d_i^{(T)}}^T \left(C_i^B + T C_i^A T^T \right)^{-1} d_i^{(T)} \right\}$ // Maximum Likelihood Estimation
end

Speaker Notes

- im Paper wurde Algorithmus nie zusammenhängend dargestellt
  - deshalb hier nochmals selber zusammengebaut
- Anfang des Algorithmus gleich wie bei Standard-ICP
- statt Gewichtung mit 0 oder 1 werden Kovarianzmatrizen verwendet
  - wie genau diese berechnet bzw gewählt werden, dazu mehr auf der nächsten Folie
- Minimierungsfunktion am Ende des Schleifendurchlaufs anders
  - nutzt Gewichtungsmatrix, die aus den Kovarianzmatrizen berechnet wird
    - mittlere Teil der Minimierungsfunktion
- im Paper wird für die Optimierung der Transformation also für arg min Maximum Likelihood Estimation verwendet
  - wählt Transformationsmatrix T so dass die Verteilung am wahrscheinlichsten ist

Theorie - GICP-Algorithmus

Variationen für Kovarianzmatrizen

$C_i^A \leftarrow \texttt{computeCovarianceMatrix}(T \cdot b_i)$
$C_i^B \leftarrow \texttt{computeCovarianceMatrix}(m_i)$

```
1  T ← T_0
2  while not converged do
3      for i ← 1 to N do
4          m_i ← FindClosestPointInA(T · b_i)
5          d_i^(T) ← b_i − T · m_i            // Residuum / Abstand
6          if ‖ d_i^(T) ‖≤ d_max then
7              C_i^A ← computeCovarianceMatrix(T · b_i)
8              C_i^B ← computeCovarianceMatrix(m_i)
9          else
10             C_i^A ← 0;    C_i^B ← 0
11         end
12     end
13     T ← arg min_T { Σ_i d_i^(T)^T (C_i^B + T C_i^A T^T)^−1 d_i^(T) }   // Maximum Likelihood Estimation
14 end
```

- für **Standard-ICP** (Point-to-Point):
  - $C_i^A \leftarrow 0$
  - $C_i^B \leftarrow 1$ → keine Oberflächenstruktur berücksichtigt (einfache Gewichtung)
- für **Point-to-Plane**:
  - $C_i^A \leftarrow 0$
  - $C_i^B \leftarrow P_i^{-1}$ → P_i ist die Projektionsmatrix auf die Ebene (beinhaltet Normalenvektor)
- für **Plane-to-Plane** (im Paper vorgeschlagene Methode):
  - `computeCovarianceMatrix` berechnet Kovarianzmatrix unter Betrachtung der nächsten 20 Punkte
    - verwendet **PCA** (Principal Component Analysis/ Hauptkomponentenanalyse)

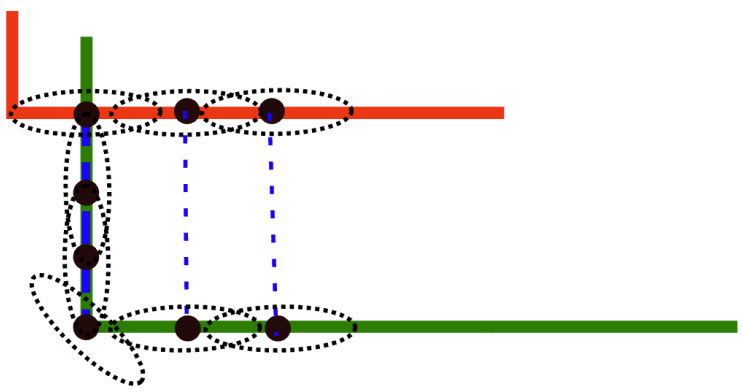

Abbildung 4: Plane-to-Plane (Segal et al., 2009)

Speaker Notes

- Wahl der Kovarianzmatrizen sind also entscheidend für den GICP-Algorithmus
- auch der Grund, warum „Generalized“ ICP
  - denn es lässt sich auch Standard-ICP und Point-to-Plane-ICP dadurch abdecken
- für Standard-ICP werden Kovarianzmatrizen einfach auf 0 bzw 1 gesetzt
  - dadurch werden die Punkte einfach gewichtet und es wird keine Oberflächenstruktur berücksichtigt
- für Point-to-Plane-ICP werden die Source-Kovarianzmatrizen auf Projektionsmatrizen gesetzt
  - diese beinhalten den Normalenvektor der Ebene
  - Oberflächenstruktur der einen Wolke berücksichtigt
- aber richtig gut erst bei dem im Paper vorgeschlagenen Verfahren
  - quasi „Plane to Plane“
- hier werden wirklich Kovarianzmatrizen ausgerechnet
  - 20 umliegende Punkte werden betrachtet
  - Verteilung mit Hauptkomponentenanalyse bestimmt
  - wenn hier eine genauere, mathematische Erklärung gewünscht
    - später darauf eingehen
    - Folie vorbereitet
- allerdings auch etwas mehr Rechenaufwand bei jeder Iteration
- Berechnen Kovarianzmatrizen geschiet bei beiden Wolken -> Berücksichtigung beider Oberflächenstrukturen
- Bild rechts zeigt Kovarianzmatrizen für paar Punkte
  - man sieht:
    - Ausrichtung/Wölbung stimmt mit Ebene überein
    - Kovarianzmatrix ist „flach“

Theorie - GICP-Algorithmus

Ergebnisse von Segal et al.

- GICP **genauer** bei simulierten und realen Daten
- immer noch relativ schnell und einfach
- Nutzen von Oberflächenstruktur **minimiert Einfluss von falschen Korrespondenzen**
- Parameter-Wahl für $d_{\max}$ nicht mehr so kritisch → leichter einsetzbar in **unterschiedlichen Szenarien**

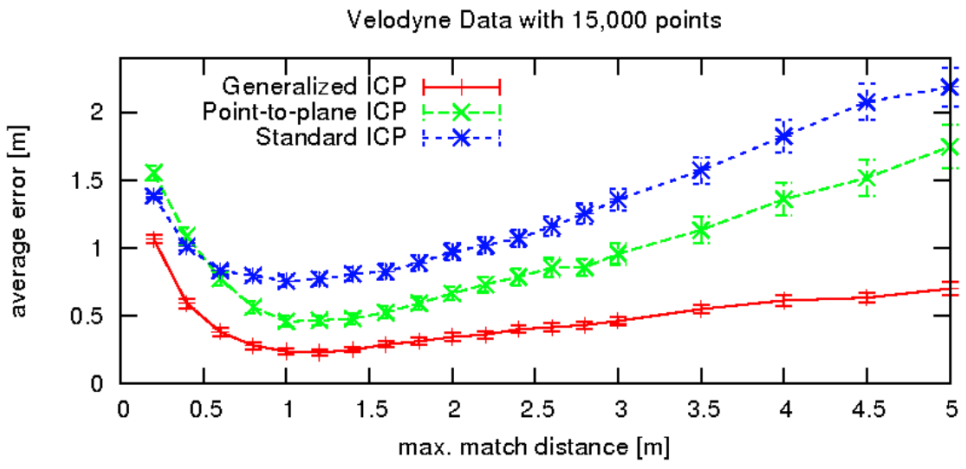

Abbildung 5: Durchschnittsfehler als Funktion von $d_{\max}$ (Segal et al., 2009)

Speaker Notes

- insgesammt GICP robuster und genauer bei simulierten und realen Daten
- dabei immer noch relativ schnell und einfach
  - auch wenn mehr Rechenaufwand durch Kovarianzmatrizen
- Nutzen von Oberflächenstruktur minimiert Einfluss von falschen Korrespondenzen, was bei Standard-ICP ein Problem war
- dadurch auch Parameter-Wahl für $d_{\max}$ nicht mehr so kritisch
  - leichter einsetzbar in unterschiedlichen Szenarien
- in Bild unten
  - Durchschnittsfehler als Funktion von $d_{\max}$
  - Generalized-ICP ganz unten, hat am die niedrigsten Fehler

Demo: Eigene Implementierung in Python

- Paper sehr mathematisch
- zwar Implementierungen auf GitHub, aber nicht wirklich lesbar

- daher eigene Implementierung - vor allem für Verständnis
- eigene **2D-GICP-Funktion**
  - Input: Punktwolken A und B, ...
  - Output: Transformationsmatrix T, ...
- Version 1:
  - Visualisierung mit generierten Input-Wolken
  - iterativ durch die Steps klicken
- Version 2:
  - Simulation eines Roboters mit LiDAR-Sensor
  - Live-Berechnung der Transformation + Visualisierung

→ *LIVE DEMO*

→ *CODE OVERVIEW*

Speaker Notes

Version 1
- Visualisierung mit generierten Input-Wolken
- Source und Target Punktwolke
  - Quadrat und Kreis als Punktwolken
  - Beide Punktwolken haben unterschiedliches Rauschen
  - Unterschiedlich viele Punkte
  - Keine Sortierung
- Covarianzmatrizzen werden dargestellt
- Bissle duchsteppen

Version 2
- Bissle mitm Roboter rumfahren
- Einmal um Kreis

=> schlechte Rotation estimation
- Einmal an gerader Wand entlang

=> schlechte Translation estimation

Demo: Eigene Implementierung in Python

Code Overview - GICP

GICP-Funktion:

```
def gicp(source_points, target_points, max_iterations=100, tolerance=1e-6,
    max_distance_correspondence=150, max_distance_nearest_neighbors=50):
    for iteration in range(max_iterations):
        # Calculate covariance covariance matrices for weight matrices
        # Will be used in loss function
        ...

        # Minimize the loss function function
        transformation = scipy.optimize.fmin_cg(
            f=loss,
            x0=transformation,
            fprime=grad_loss)

        # Check for convergence
        if delta_loss < tolerance:
            break

    return transformation
```

Demo: Eigene Implementierung in Python

Code Overview - Roboter

GICP-Aufruf:

```
transformation_matrix = gicp(
            _source_points,
            _target_points,
            max_distance_nearest_neighbors=200,
            tolerance=1,
        )
```

Demo: Eigene Implementierung in Python

Code Overview - Roboter

Berechnung der neuen Schätzung:

```
# Get delta x, y and yaw from transformation matrix
delta_x = -transformation_matrix[0, 2]
delta_y = -transformation_matrix[1, 2]
delta_yaw = -np.arctan2(transformation_matrix[1, 0], transformation_matrix[0,
0])

# Calculate estimations for new position and orientation
new_estimated_x = last_estimated_x
    + delta_x * math.cos(last_estimated_yaw)
    - delta_y * math.sin(last_estimated_yaw)

new_estimated_y = last_estimated_y
    + delta_x * math.sin(last_estimated_yaw)
    + delta_y * math.cos(last_estimated_yaw)

new_estimated_yaw = last_estimated_yaw + delta_yaw
```

Implementierung in ROS - Versuch

Leitfrage

Ist Generalized-ICP besser als Standard-ICP und wie verhält sich der Algorithmus in unterschiedlichen Szenarien?

Speaker Notes

- Vorbedingungen:
  - Bag File: beispiel trajektorie wird in ROS-Bag-Datei gespeichert, die als Input für die Experimente dient und immmer den gleichen Datensatz zur Verfügung stellt
  - Skript für Nodes: Skripte, die die notwendigen ROS-Nodes starten und konfigurieren.
  - Yaml-Dateien als Konfigurationsdateien im YAML-Format, die die Parameter und Einstellungen für die Experimente enthalten.
- Szenarien:
  - Auswertung

Implementierung in ROS - Versuch

Parameterisierung

```
//name des odom topics
this->declare_parameter("odom_topic", "");
//name des icp topics
this->declare_parameter("gicp_result_topic", "");
//name des zeitmessung topics
this->declare_parameter("alignment_time_topic", "");
//parameter ob gicp oder icp verwendet wird
this->declare_parameter("gicp", false);
//ob manuelle transformation gepublished wird
this->declare_parameter("publish_tf", false);

//icp parameter
this->declare_parameter("max_correspondence_distance", 0.0);
this->declare_parameter("maximum_iterations", 0);
this->declare_parameter("transformation_epsilon", 0.0);
this->declare_parameter("euclidean_fitness_epsilon", 0.0);
```

Speaker Notes

-max correspondence distance: maximale distanz mit der ein punkt aus der source wolke mit einem punkt aus der target wolke korrespondieren kann - maximum iterations: maximale anzahl an iterationen die der algorithmus -transformation epsilon:die maximal zulässige quadratische Differenz zwischen zwei aufeinanderfolgenden Transformationen - euclidean fitness epsilon: Der maximal zulässige euklidische Fehler zwischen zwei aufeinanderfolgenden Schritten in der ICP-Schleife fehler = durschnitt aller Unterschiede zwischen den korrespondierenden Punkten

Implementierung in ROS - Versuch

Parameterisierung über YAML file

```yaml
gicp_lio:
  ros__parameters:
    gicp: True
    publish_tf: False
    alignment_time_topic:
"galignment_time"
    odom_topic: "glidar_odom"
    gicp_result_topic: "glidar_odom_eval"
    max_correspondence_distance: 0.2
    maximum_iterations: 100
    transformation_epsilon: 0.000000001
    euclidean_fitness_epsilon: 0.00001
```

```yaml
gicp_lio:
  ros__parameters:
    gicp: False
    publish_tf: False
    alignment_time_topic:
"alignment_time"
    odom_topic: "lidar_odom"
    gicp_result_topic: "lidar_odom_eval"
    max_correspondence_distance: 0.2
    maximum_iterations: 100
    transformation_epsilon: 0.000000001
    euclidean_fitness_epsilon: 0.00001
```

Implementierung in ROS - Versuch

Implementierung ICP & GICP

- ICP:

```
pcl::IterativeClosestPoint<pcl::PointXYZ, pcl::PointXYZ> icp;
icp.setInputSource(src);
icp.setInputTarget(tgt);
pcl::PointCloud<pcl::PointXYZ>::Ptr output(new
pcl::PointCloud<pcl::PointXYZ>);
icp.align(*output);
```

- GICP:

```
pcl::GeneralizedIterativeClosestPoint<pcl::PointXYZ, pcl::PointXYZ> gicp;
gicp.setInputSource(src);
gicp.setInputTarget(tgt);
pcl::PointCloud<pcl::PointXYZ>::Ptr output(new
pcl::PointCloud<pcl::PointXYZ>);
gicp.align(*output);
```

Speaker Notes

- ICP und GICP sind beide in der PCL-Bibliothek implementiert
- beide benötigen als Input die Source- und Target-Punktwolke
- align-Funktion berechnet die Transformation
- icp.align(output): Führt den ICP-Algorithmus aus, um die beste Übereinstimmung zwischen der Quell- und Zielpunktwolke zu finden und speichert das Ergebnis in der Ausgabepunktwolke

Implementierung in ROS - Versuch

Zeitmessung

```
auto start = std::chrono::high_resolution_clock::now();
icp.align(*output);
transformation = icp.getFinalTransformation();
auto finish = std::chrono::high_resolution_clock::now();

std::chrono::duration<double> elapsed = finish - start;
std_msgs::msg::Float64 time_msg;
time_msg.data = elapsed.count();
time_publisher_->publish(time_msg);
```

Speaker Notes

- Zeitmessung wird mit der C++-Chrono-Bibliothek durchgeführt
- start und finish markieren den Anfang und das Ende der Zeitmessung
- elapsed berechnet die Dauer der Zeitmessung
- time_msg wird erstellt und die Zeit wird in die Nachricht geschrieben
- time_publisher veröffentlicht die Nachricht auf dem entsprechenden Topic
- überprüfung ob GICP auch wirklich aufwendiger in der Berechnung
- wie ändern Parameter die Zeit

Implementierung in ROS - Versuch

Problem: Aufsummierende Fehler

```
// reduce tick speed in topic_callback
tick++;
if (tick % 3 != 0) {
  return;
}
```

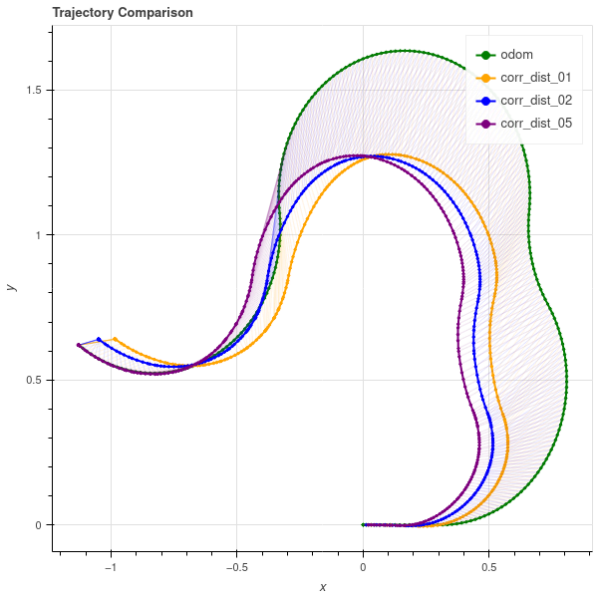

Abbildung 6: Trajectory plot with higher tick speed

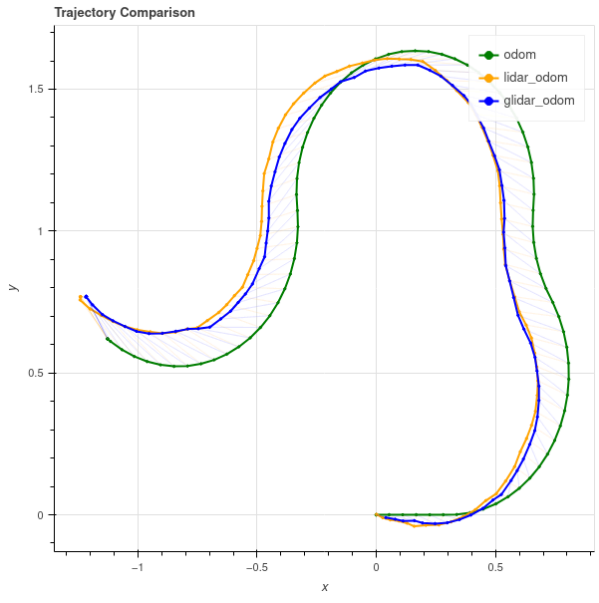

Abbildung 7: Trajectory plot with lower tick speed

Speaker Notes

- Problem: Aufsummierende Fehler
- schlechte Ergebnisse wenn jeder Tick berücksichtigt wird
- weniger Aufrufe der (G)ICP Algorithmen
- weniger Datenpunkte
- deutlich bessere Ergebnisse wenn nur jeder dritte Tick berücksichtigt wird
- rechenleistung wird gespart

Implementierung in ROS - Versuch

Turtlebot3 World

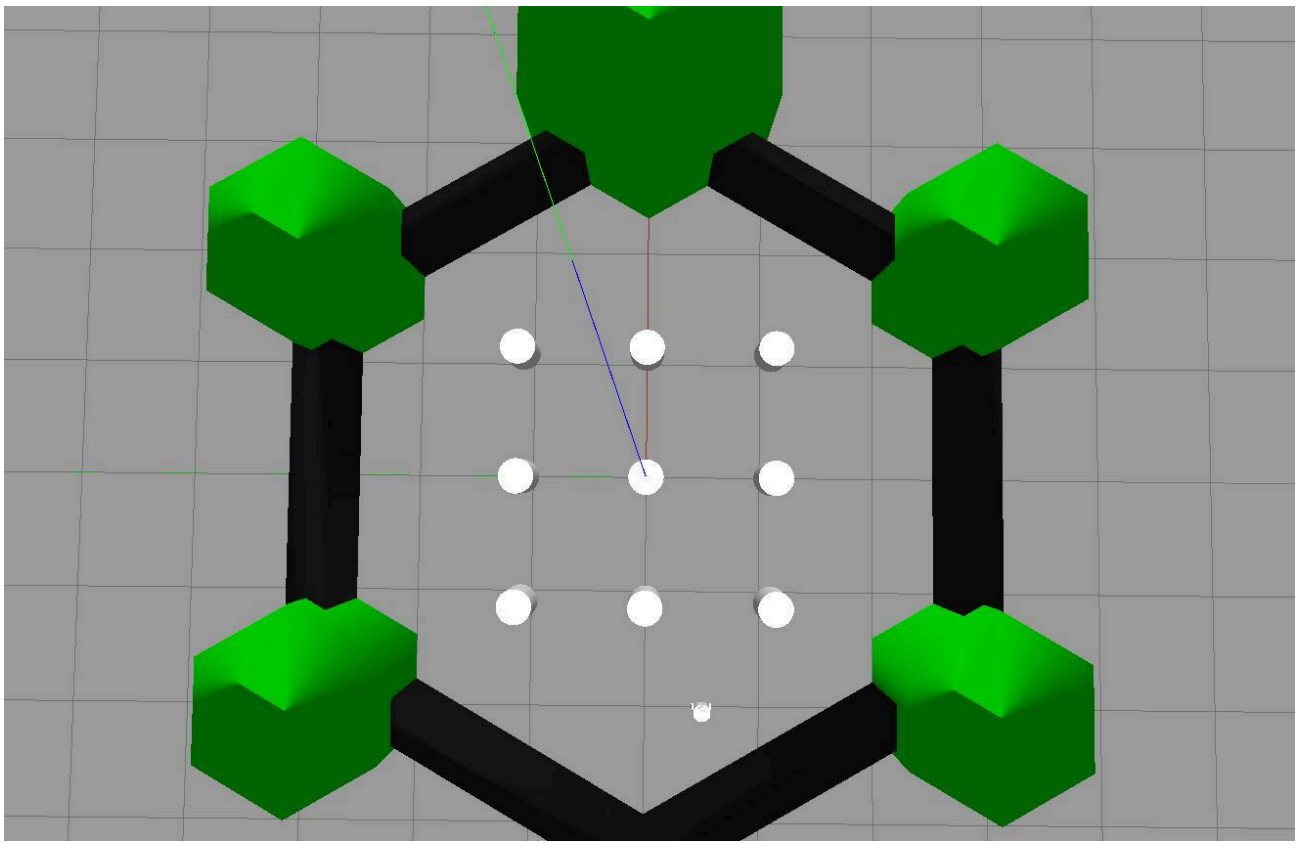

Abbildung 8: Screenshot Gazebo

Speaker Notes

- Turtlebot3 World: Standard Gazebo-Welt für Turtlebot3
- sechseck und 9 zylinder
- mittel komplexe Umgebung
- viele Datenpunkte

Implementierung in ROS - Versuch

Turtlebot3 World

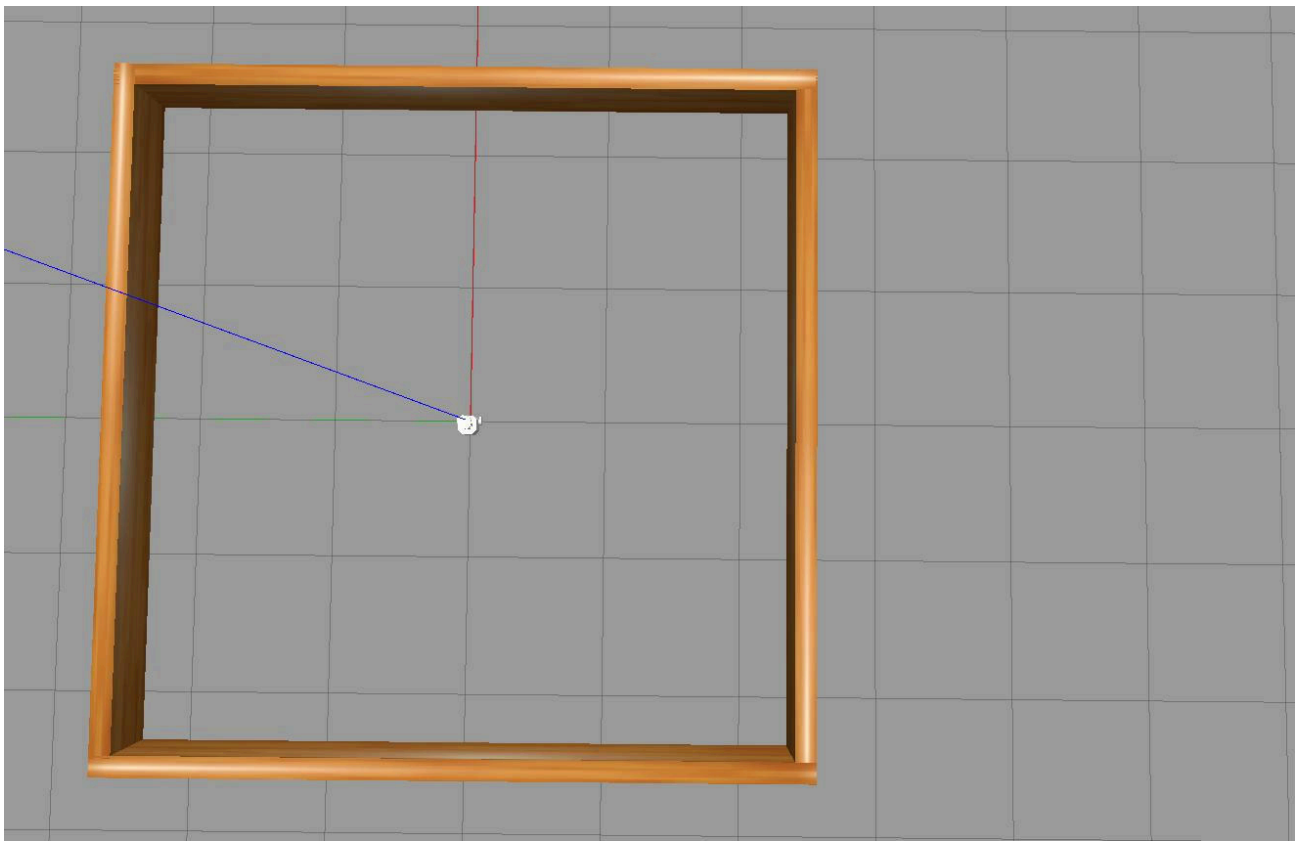

Abbildung 9: Screenshot Gazebo

Speaker Notes

- rechteck
- keine Hindernisse
- einfachste Umgebung
- wenig Datenpunkte

Implementierung in ROS - Versuch

Turtlebot3 ICP World

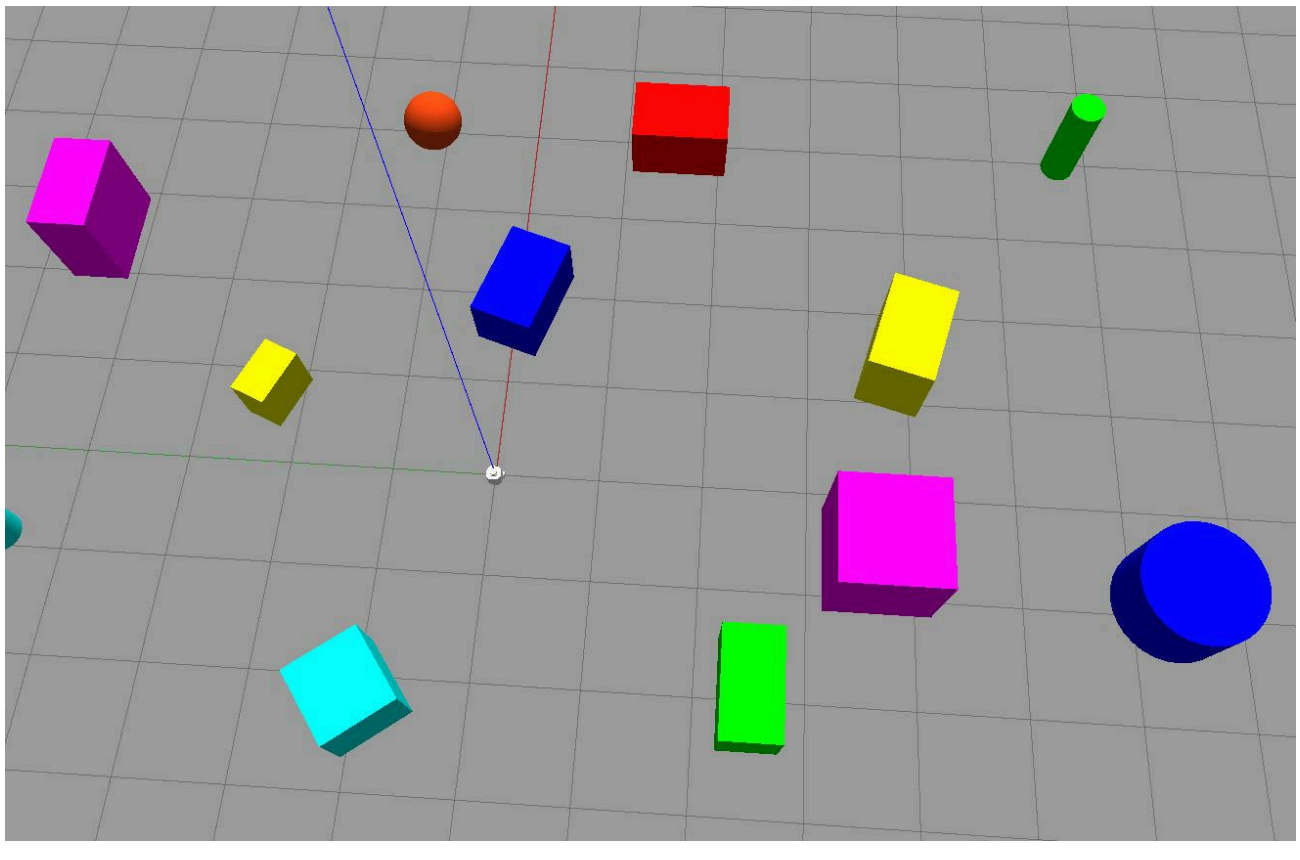

Abbildung 10: Screenshot Gazebo

Speaker Notes

- icp welt von aufgabe 2
- unterschiedlichste objekte
- keine begrenzung der umgebung
- komplexeste Umgebung
- mittel viele Datenpunkte

Auswertung

Drei unterschiedliche Maps

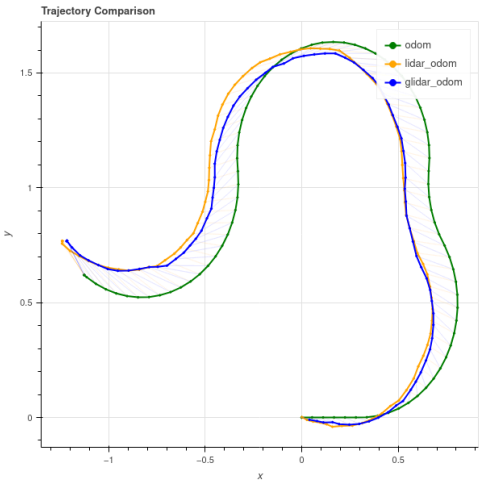

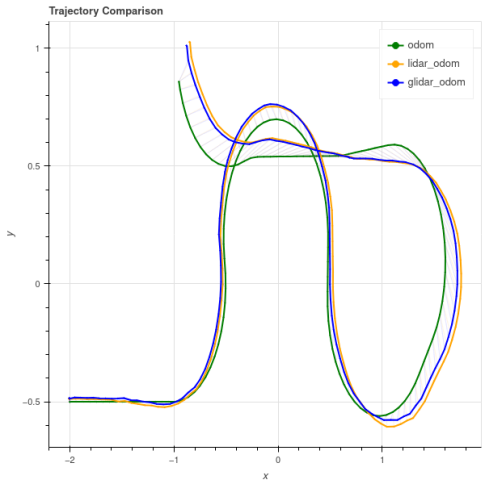

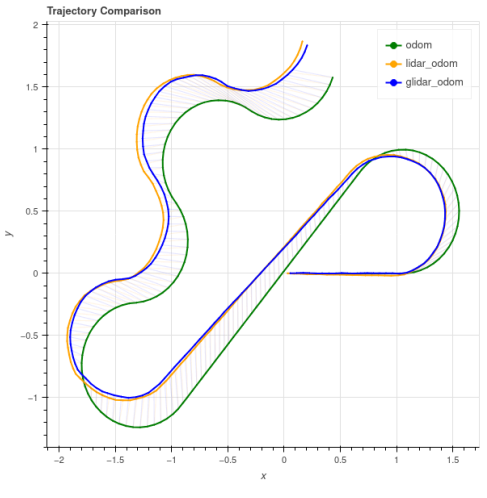

Auswertung

Unterschiedliche Parameterisierung

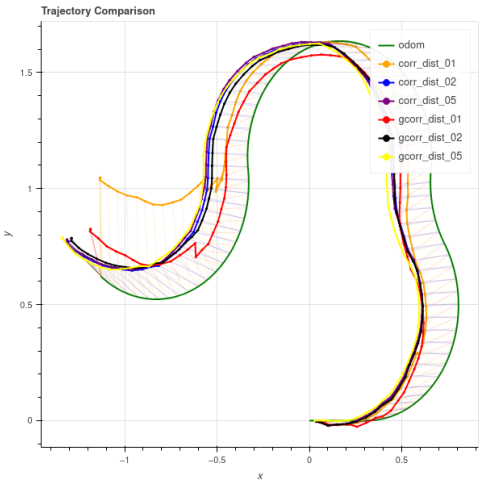

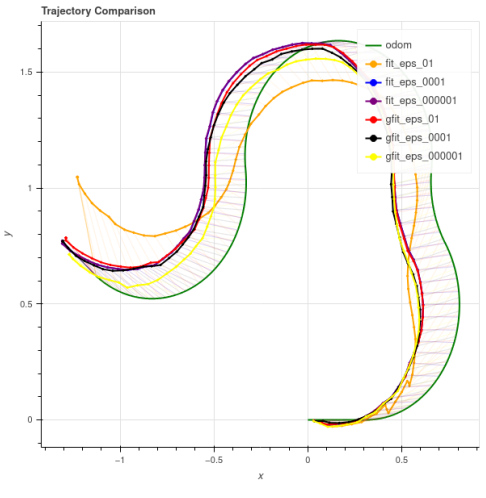

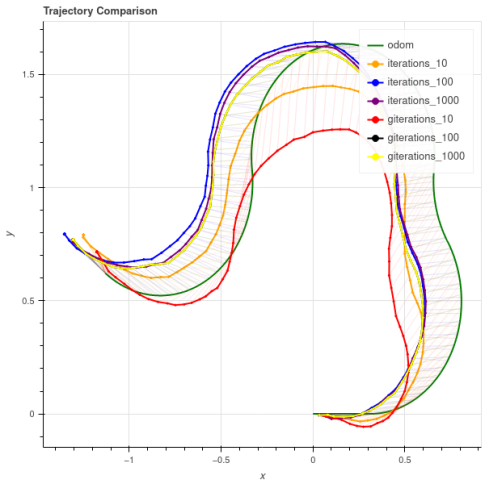

Speaker Notes

corr_dist: max correspondence distance
- icp mit 0,1 deutlich schlechter in position und orientation
- gicp mit 0,1 sogar am besten
- keine großen Unterschiede von 0,2 und 0,5

=> gicp robuster gegenüber Parameterwahl
- alignment time bei gicp deutlich höher
- alignment time bei gicp und icp parameterunabhängig

fit_eps: euclidean fitness epsilon
- icp mit 0,1 deutlich schlechter in position und orientation
- gicp mit 0,00001 am besten
- rest relativ ähnlich
- alignment gleich wie bei corr_dist

=> gicp robuster gegenüber Parameterwahl
iterations: maximum iterations
- gicp mit 10 deutlich schlechter in position und orientation
- icp mit 10 deutlich schlechter in orientation
- rest relativ ähnlich
- alignment time bei gicp 10 iterations niedriger => algorithmus terminiert
- restliche Zeit bei gicp und icp kaum unterschiede

Auswertung

Fünf Durchgänge mit Standardparameterisierung (ICP & GICP)

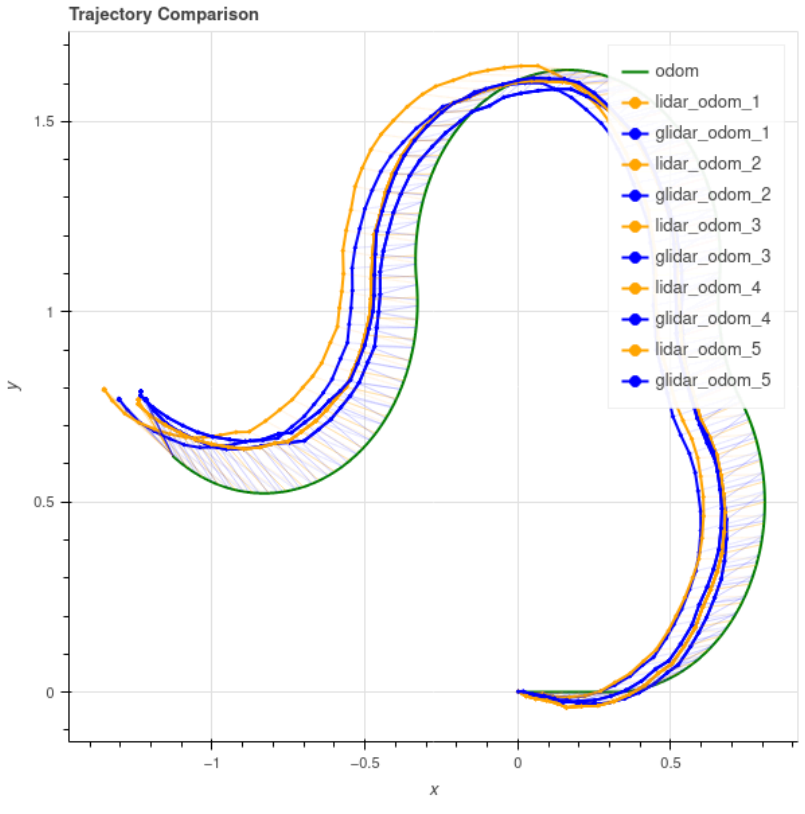

Speaker Notes

- durchläufe relativ konstant
- gibt abweichungen in position und orientation
- gibt fast perfekt gleiche trajectories

=> Ist Simulation

Fazit

- Leitfrage: Ist Generalized-ICP besser als Standard-ICP und wie verhält sich der Algorithmus in unterschiedlichen Szenarien?

- keine deutlich besseren Ergebnisse bei GICP
- Parameter-Wahl nicht so kritisch wie bei ICP kann bestätigt werden
- keine marginalen Unterschiede zwischen ICP & GICP in den unterschiedlichen Maps
- GICP ist aufwendiger in der Berechnung
- Abhängigkeit von der Simulationsumgebung
- Unterschiede zu Paper, da 3D-Scan und deutlich mehr Punkte

(Bild-)Quellen

Igor Bogoslavskyi. (2021). https://nbviewer.org/github/niosus/notebooks/blob/master/icp.ipynb

Kok-Lim Low. (2004). *Linear Least-Squares Optimization for Point-to-Plane ICP Surface Registration*. https://www.comp.nus.edu.sg/~lowkl/publications/lowk_point-to-plane_icp_techrep.pdf

Segal, A. V., Hähnel, D., & Thrun, S. (2009). Generalized-ICP. *Robotics: Science and Systems*. https://api.semanticscholar.org/CorpusID:231748613

Anhang - Bestimmung der Kovarianzmatrizen bei Plane-to-Plane GICP

```
def compute_covariance_matrix_single_point(point, neighbors):
  epsilon = 1e-6
  covariance_ground = np.array([[epsilon, 0],
                                [0,       1]])
  covariance = np.cov(neighbors, rowvar=False)
  U, D, V = np.linalg.svd(covariance)                 # Singular Value
Decomposition
  covariance_aligned = U @ covariance_ground @ U.T  # Align covariance matrix
  return covariance_aligned
```

Single Value Decomposition

- Zerlegung einer Matrix in drei Matrizen:
  - Rotation ⟶ Skalierung ⟶ Rotation
- wird hier verwendet, um die Rotation der Kovarianzmatrix zu bestimmen
  - Rotation sollte so sein, wie die Nachbarn liegen (Ebene)
- die Rotation wird dann auf die „Standard-Kovarianzmatrix“ angewendet
  - bildet so die Ebene ab

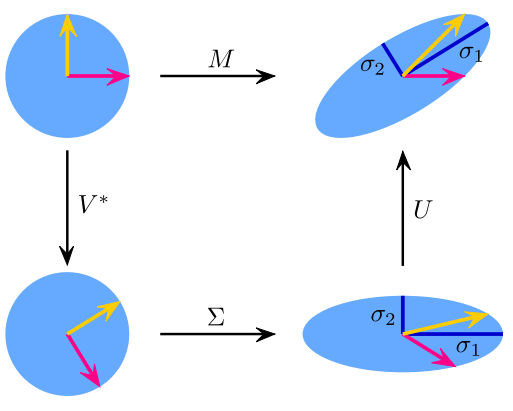

Abbildung 11: Singular Value Decomposition (Wikipedia)

Speaker Notes

- es wird Single Value Decomposition verwendet
- Zerlegung einer Matrix in drei Matrizen:
  - Rotation ⟶ Skalierung ⟶ Rotation
- wird hier verwendet, um die Rotation der Kovarianzmatrix zu bestimmen
  - Rotation sollte so sein, wie die Nachbarn liegen
- die Rotation wird dann auf die „Standard-Kovarianzmatrix“ angewendet
  - bildet so die Ebene ab
- in Paper wird in Fußnote erwähnt, dass sie bei ihrer Implementierung PCA (Hauptkomponentenanalyse) verwendet haben
- bei unserem eigene 2D-Skript hat das allerdings nicht so gut funktioniert wie die Alternative mit SVD